矩阵分解与特征降维 C06

2020/10/30 胡俊峰 北京大学信息科学技术学院

主要内容

→HITS算法

- **Pandas**表的聚集与关联运算
- ▶特征分析与降维
- →数据可视化

Data Aggregations on Multi-Indices

- Pandas has built-in data aggregation methods,
- such as mean(), sum(), and max().
- For hierarchically indexed data, these can be passed a level parameter that controls which subset of the data the aggregate is computed on.

Group by certain Key

```
data_mean = health_data.mean(level='year')
data_mean
```

subject	Bob		Guid	0	Sue	
type	HR	Temp	HR	Temp	HR	Temp
year						
2013	37.5	38.2	41.0	35.85	32.0	36.95
2014	38.5	37.6	43.5	37.55	56.0	36.70

1	health_data								
	subject	Bob		Guido		Sue			
	type	HR	Temp	HR	Temp	HR	Temp		
year	visit								
2013	1	31.0	38.7	32.0	36.7	35.0	37.2		
	2	44.0	37.7	50.0	35.0	29.0	36.7		
2014	1	30.0	37.4	39.0	37.8	61.0	36.9		
	2	47.0	37.8	48.0	37.3	51.0	36.5		

Combining Datasets: Merge and Join

- one-to-one
- many-to-one
- many-to-many joins.

Combining Datasets: Concat and Append

```
ser1 = pd. Series(['A', 'B', 'C'], index=[1, 2, 3])
 2 | ser2 = pd. Series(['D', 'E', 'F'], index=[4, 5, 6])
 3 pd. concat([ser1, ser2])
                                 df1 = make_df('AB', [1, 2])
                               2 df2 = make_df('AB', [3, 4])
                               3 display('df1', 'df2', 'pd.concat([df1, df2])')
dtype: object
                                          df2 pd.concat([df1, df2])
                              df1
                                  A B
                                            А В
                                                        А В
                               1 A1 B1 3 A3 B3 1 A1 B1
                               2 A2 B2 4 A4 B4
                                                      2 A2 B2
                                                      3 A3 B3
                                                      4 A4 B4
```

One-to-one joins:

```
df1
                           df2
   employee
                  group
                              employee hire_date
                           0
        Bob
              Accounting
                                   Lisa
                                            2004
        Jake Engineering
                                   Bob
                                             2008
2
        Lisa Engineering
                           2
                                            2012
                                   Jake
3
        Sue
                    HR
                            3
                                   Sue
                                             2014
```

```
1 df3 = pd.merge(df1, df2)
2 df3
```

	employee	group	hire_date
0	Bob	Accounting	2008
1	Jake	Engineering	2012
2	Lisa	Engineering	2004
3	Sue	HR	2014

Many-to-one joins:

df3

	employee	group	hire_date
0	Bob	Accounting	2008
1	Jake	Engineering	2012
2	Lisa	Engineering	2004
3	Sue	HR	2014

df4

	group	supervisor
0	Accounting	Carly
1	Engineering	Guido
2	HR	Steve

pd.merge(df3, df4)

	employee	group	hire_date	supervisor
0	Bob	Accounting	2008	Carly
1	Jake	Engineering	2012	Guido
2	Lisa	Engineering	2004	Guido
3	Sue	HR	2014	Steve

推荐算法与搜索排名

- **▶ PCA**降维与特征空间
- **→ HITS**算法与搜索排名
- ► SVD与隐含语义挖掘
- ▶协同过滤算法

协方差矩阵的物理意义

$$C(p;q) = \frac{1}{N} \sum_{k=1}^{N} X_p^{(k)} X_q^{(k)}$$

对角线(p;p)上的元素: 第p维特征的方差

矩阵(p;q)元的大小反映了所有样本第p维和第q维数据的相关性(若不相关,则为0)

PCA (主成分分解)

一 对于实对称矩阵,存在一组正交变换使其对角化

新特征的方差

Q^T 新特征空间的基底

```
eigVals, eigVecs = np. linalg.eig(X_centered. T. dot(X_centered))
 2 eigVecs
array([[-0.91116273, -0.41204669],
       [ 0.41204669, -0.91116273]])
    orange = '#FF9A13'
 2 blue = '#1190FF'
 3 plt.plot([0, eigVecs[0][0]], [0, eigVecs[1][0]], orange)
 4 plt.plot([0, eigVecs[0][1]], [0, eigVecs[1][1]], blue)
 5 plt.plot(X_centered[:,0], X_centered[:,1], '*')
 6 plt. xlim(-3, 3)
   plt.ylim(-3, 3)
   plt.show()
 -1
 -2
```

PCA-主成分分析

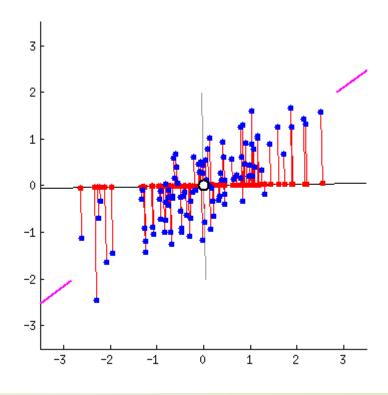
- •对原始样本进行(线性变换)基变换可以对原始样本给出不同的表示
- •基的维度小于数据的维度可以起到降维的效果
- •对基变换后新的样本求其方差,选取使其方差最大的基
- •新的基之间的协方差要为0

$$X = \left(egin{array}{cccc} a_1 & a_2 & \dots & a_m \ b_1 & b_2 & \dots & b_m \end{array}
ight)$$

协方差矩阵

$$rac{1}{m}XX^ op = \left(egin{array}{ccc} rac{1}{m}\sum_{i=1}^m a_i^2 & rac{1}{m}\sum_{i=1}^m a_ib_i \ rac{1}{m}\sum_{i=1}^m a_ib_i & rac{1}{m}\sum_{i=1}^m b_i^2 \end{array}
ight)$$

目标: 基变换后的新样本的协方差矩阵是对角化的



PCA-主成分分析

X:原始数据,每一列为一个数据

P: 是一组基按行组成的矩阵

Y: 是X对P做基变换的后的新数据

C: 原始数据X的协方差矩阵

D: Y的协方差矩阵

我们找的P,正好是让原协方差 矩阵对角化的P

$$\begin{split} D &= \frac{1}{m} Y Y^{\top} \\ &= \frac{1}{m} (PX)(PX)^{\top} \\ &= \frac{1}{m} P X X^{\top} P^{\top} \\ &= P(\frac{1}{m} X X^{\top}) P^{\top} \\ &= PCP^{\top} \\ &= P \left(\frac{\frac{1}{m} \sum_{i=1}^{m} a_i^2}{\frac{1}{m} \sum_{i=1}^{m} a_i b_i} \right) P^{\top} \\ &= P \left(\frac{\frac{1}{m} \sum_{i=1}^{m} a_i b_i}{\frac{1}{m} \sum_{i=1}^{m} b_i^2} \right) P^{\top} \end{split}$$

于是,只需对协方差矩阵C进行特征分解,对求得的特征值进行排序,再对特征向量取前 K列组成的矩阵乘以原始数据矩阵X,就得到了我们需要的降维后的数据矩阵Y。

PCA数据特征降维

[-2.62614497, 0.16338496],

[-2.88638273, -0.57831175],

[-2.6727558, -0.11377425],

[-2.50694709, 0.6450689],

[-2.61275523, 0.01472994],

```
In [78]:
            1 from sklearn. decomposition import PCA # 1. Choose the model class
                                                       # 2. Instantiate the model with hypery
              2 \mod 1 = PCA(n_{components}=2)
                model.fit(X_iris)
                                                       # 3. Fit to data. Notice y is not spec
              4 X 2D = model. transform(X iris) # 4. Transform the data to two dimensi
              5 X 2D
  Out[78]: array([[-2.68412563, 0.31939725],
                   [-2.71414169, -0.17700123],
                   [-2.88899057, -0.14494943],
                   [-2.74534286, -0.31829898],
                   [-2.72871654, 0.32675451],
                   [-2.28085963, 0.74133045],
                   [-2.82053775, -0.08946138],
```

```
sns.lmplot("PCA1", "PCA2", hue='species', data=iris, fit_reg=False)
 1.5
 1.0
 0.5
                                                          species
 0.0
                                                           setosa
                                                           versicolor
                                                           virginica
-0.5
-1.0
```

 $1r1s[PCAT] = X_2D[:, 0]$

iris['PCA2'] = X_2D[:, 1]

主成分分析与聚类

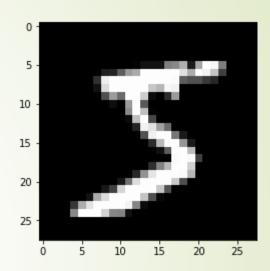
```
import pandas as pd

: train = pd.read_csv('./python_course/train.csv')
    print(train.shape)|

    (42000, 785)

: target = train['label']
    train = train.drop("label", axis=1)
    X= train[:6000].values
    Target = target[:6000]
    print(X.shape)

    (6000, 784)
```



	label	pixel0	pixel1	pixel2	pixel3	pixel4	pixel5	pixel6	pixel7	pixel8
0	1	0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0
2	1	0	0	0	0	0	0	0	0	0
3	4	0	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0	0	0

PCA — 手写数字识别

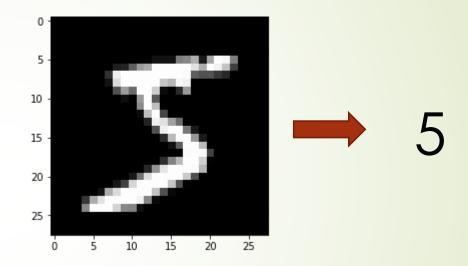
标准化数据,保证每个维度的数据方差是1,均值为0,使得预测结果不会被某些数值大的值主导,保证'公平'

计算特征值和特征向量

从特征值由大到小排列

计算每个方差所占能量的比例

聚类与识别

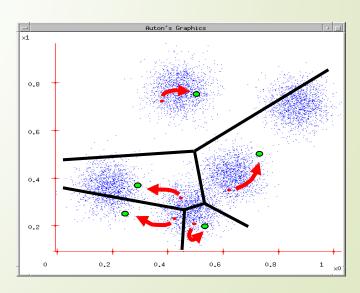


```
100
                                                          Second Principal Component
                                                            75
                                                            50
                                                            25
from sklearn. cluster import KMeans # KMeans cluste
                                                           -25
kmeans = KMeans(n_clusters=10)
                                                           -50
                                                           -75
X_clustered = kmeans.fit_predict(tsne_results)
                                                                         First Principal Component
fig = plt.figure()
ax1 = fig.add_subplot(111)
#设置标题
ax1.set_title('KMeans Clustering (LDA)')
#设置X轴标签
plt. xlabel ('First Principal Component')
#投置Y轴标签
plt.ylabel ('Second Principal Component')
#画數点图
ax1.scatter(tsne_results[:,0], tsne_results[:,1], c = X_clustered, cmap='jet', marker = 'o')
#显示所画的图
plt.show()
```

KMeans Clustering (LDA)

K-means 硬聚类分析

- ▶ 类质心按分布密度的贪心求解法
- ■局部最优解



距离加权方案与核函数 (kernel)

$$P(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^{n} K(\mathbf{x} - \mathbf{x}_{i})$$

A function of some finite number of data points

 $X_1...X_n$

Examples:

Epanechnikov Kernel

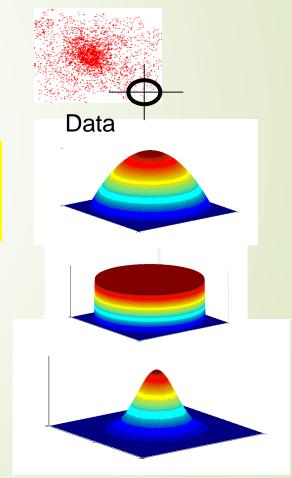
Uniform Kernel

Normal Kernel

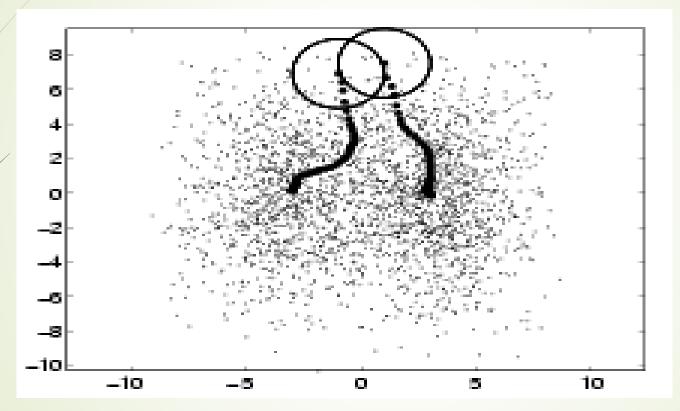
$$K_{E}(\mathbf{x}) = \begin{cases} c\left(1 - \|\mathbf{x}\|^{2}\right) & \|\mathbf{x}\| \leq 1\\ 0 & \text{otherwise} \end{cases}$$

$$K_{U}(\mathbf{x}) = \begin{cases} c & \|\mathbf{x}\| \le 1 \\ 0 & \text{otherwise} \end{cases}$$

$$K_N(\mathbf{x}) = c \cdot \exp\left(-\frac{1}{2} \|\mathbf{x}\|^2\right)$$

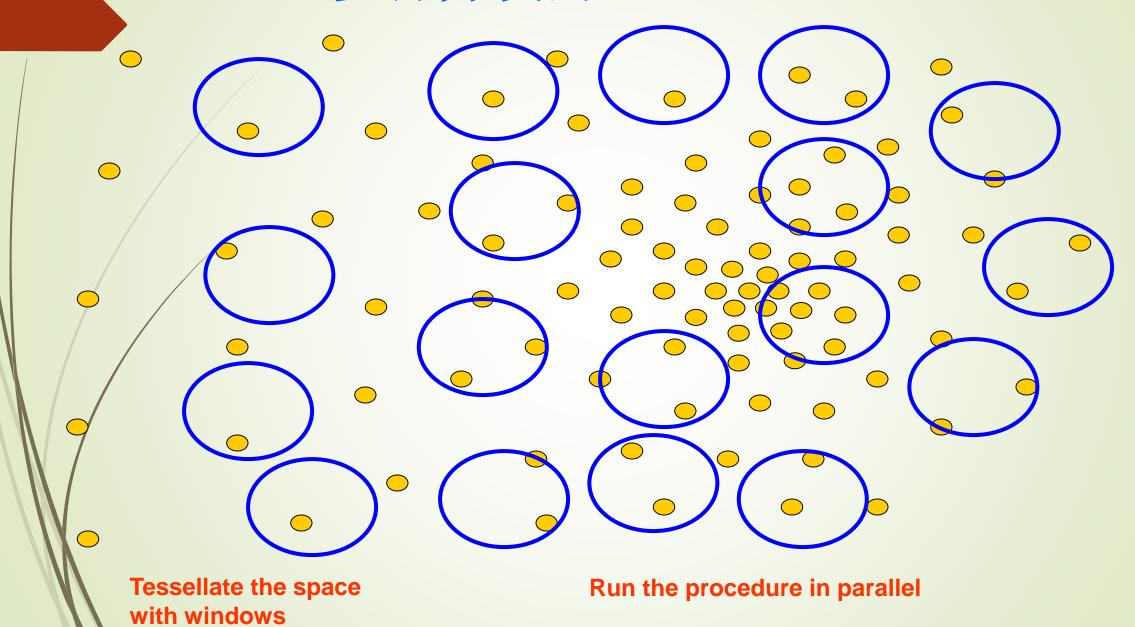


在核函数约束下呈现的按梯度贪心的收敛轨迹 mean shift trajectories



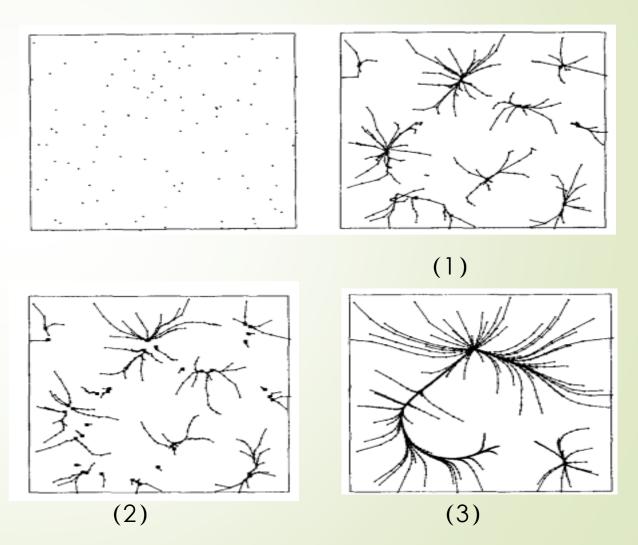
Window tracks signify the steepest ascent directions

多源并发的mean-shift



Mean shift trajectories with different kernal

- Same sample space
 - (1) Uniform Kernel
 - (2) truncated Normal Kernel
 - 3 nontruncated Normal Kernel



HITS算法(Hyperlink-induced Topic Search)

网络分析基本 方法及其应用 张涵

网络分析基本 思想

静态结构分析:基础统计 基础统计 社会群体及社会角色 弱关系及桥 点的同质

对强弱关系的反思

对结构的深入 研究:建立模 型

网络平衡 度数分布的深入研 究:模型的实例 **网络的链接分析及预** 測

数据收集及处

首先,通过关键词在文档中是否出现,得到相关网页集合及其链接关系。

- 每个网页有两个值: a(权威值,入度高)及h (hub,中枢值,出度高)
- 通过反复迭代计算,得出得分最高的网页。

张涵

网络分析基本 思想

静态结构分 析:基础统计

基础统计

社会群体及社会角色

弱关系及标

点的同儿

性(homophily): 强美系的影响

对强弱关系的反思

对结构的深入 研究:建立模型

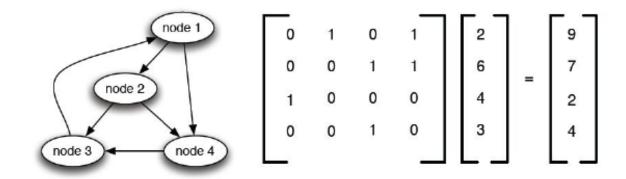
网络平衡

度数分布的深入码 究:模型的实例

网络的链接分析及预 测

数据收集及处理

抽样方法 作图



定义n个网页之间链接关系的邻接矩阵为M,即 M_{ij} 为 $1 \longleftrightarrow 从网页i到i有链接,则网页i的中枢值为:$

$$a_i \leftarrow M_{1i}h_1 + M_{2i}h_2 + ...M_{ni}h_n$$
 (3)

$$h_i \longleftarrow M_{i1}a_1 + M_{i2}a_2 + ...M_{in}a_n$$
 (4)

 $h^{k} = (h_{1}, h_{2}, ...h_{n})^{T}, a^{k} = (a_{1}, a_{2}, ...a_{n})^{T}$ 为运行了k次的时候,n个网页的中枢,权威向量,则转换规则为: (先更新 a^{k})

张涵

网络分析基本 思想

静态结构分析:基础统计

基础统计

社会群体及社会角色

弱关系及桥

点的同质

性(homophily): 强。 系的影响

对强弱关系的反员

对结构的深入 研究:建立模 型

网络平衡

度数分布的深入码 究:模型的实例

网络的链接分析及预测

数据收集及处理

抽样方法

$$a^k = M^T h^{k-1} (5)$$

$$h^k = Ma^k \tag{6}$$

 h^{0}, a^{0} 的元素都为1 迭代可得: $a^{1}=M^{T}h^{0}, h^{1}=MM^{T}h^{0},...$

$$a^k = (M^T M)^{k-1} h^0 (7)$$

$$h^k = (MM^T)^k h^0 (8)$$

定理: n*n的实对称矩阵有n个特征值, 且不同特征值的特征向量彼此正交(即特征向量构成线性空间的一组基底)

网络分析基本 方法及其应用

张涵

网络分析基本 思想

静态结构分 析:基础统计

基础统计

社会群体及社会角色

弱关系及桥

点的同质

性(homophily): 强美 系的影响

对强弱关系的反应

对结构的深入 研究:建立模型

网络平衡

度数分布的深入。 究:模型的实例

网络的链接分析及5 测

数据收集及**处** 理

抽样方法 作園 设 $(M^TM)^{k-1}$ 的特征值为 $C_1, C_2, ..., C_n, \mathbb{1} C_1 > C_2 > ... > C_n,$ 对应的特征向量为 $Z_1, Z_2, ..., Z_n, \pi h^0$ 在基底下的表示为

$$h_0 = q_1 z_1 + q_2 z_2 + \dots + q_n z_n \tag{9}$$

则

$$h^{k} = (MM^{T})^{k}h^{0}$$

$$= (MM^{T})^{k}(q_{1}z_{1} + q_{2}z_{2} + ...q_{n}z_{n})$$

$$= q_{1}(MM^{T})^{k}z_{1} + q_{2}(MM^{T})^{k}z_{2} + ... + q_{n}(MM^{T})^{k}t_{n}^{2}$$

$$= q_{1}c_{1}^{k}z_{1} + q_{2}c_{2}^{k}z_{2} + ...q_{n}c_{n}^{k}z_{n}$$
(13)

网络分析基本 方法及其应用

张涵

网络分析基本 思想

静态结构分 析:基础统计

基础统计

社会群体及社会角色

弱关系及桥

点的同质 性(homophily): 强。

对强弱关系的反思

对结构的深入 研究:建立模 型

网络平衡

度数分布的深入研究:模型的实例

网络的链接分析及预 测

数据收集及处理

抽样方法

如果要收敛, 需要对每项正规化。则

$$h^{k} = \frac{(MM^{T})^{k} h^{0}}{\|(MM^{T})^{k} h^{0}\|}$$
 (14)

$$= \frac{q_1 c_1^k z_1 + q_2 c_2^k z_2 + ... q_n c_n^k z_n}{\|q_1 c_1^k z_1 + q_2 c_2^k z_2 + ... q_n c_n^k z_n\|}$$
(15)

$$= \frac{q_1 z_1 + q_2 \left(\frac{c_2}{c_1}\right)^k z_2 + ... q_n \left(\frac{c_2}{c_1}\right)^k z_n}{\|q_1 z_1 + q_2 \left(\frac{c_2}{c_1}\right)^k z_2 + ... q_n \left(\frac{c_2}{c_1}\right)^k z_n\|}$$
(16)

$$= \frac{q_1 z_1}{\|q_1 z_1\|} \tag{17}$$

故 h_k 收敛,同理可得 a_k 收敛

奇异值分解

- $N \times M$ 矩阵X, 把每一行当成一个点。设r = rank(X)。

- $\vec{v}_r = argmax_{|\vec{v}|=1,\vec{v}\perp\vec{v}_1,\vec{v}\perp\vec{v}_2,...,\vec{v}\perp\vec{v}_{r-1}}|X\vec{v}|$
- $\Rightarrow \Rightarrow \sigma_i = |X\vec{v}_i|, \overrightarrow{u_i} = \frac{1}{\sigma_i} X\vec{v}_i, 1 \le i \le r$

奇异值分解

▶ $N \times M$ 矩阵X,把每一行当成一个点。设r = rank(X)。

$$X = \sum_{i=1}^{r} \sigma_i \vec{u}_i \vec{v}_i^T = \begin{bmatrix} | & & | \\ \vec{u}_1 & \dots & \vec{u}_r \end{bmatrix} \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & | \end{bmatrix} \begin{bmatrix} -\vec{v}_1^T - \\ \dots & \\ -\vec{v}_r^T \end{bmatrix} = UDV^T$$

- -U,D,V分别为 $N \times r,r \times r,M \times r$ 矩阵

numpy.linalg.svd

numpy.linalg.svd(a, full_matrices=True, compute_uv=True)

[source]

Singular Value Decomposition.

When a is a 2D array, it is factorized as $u \otimes np$. $diag(s) \otimes vh = (u * s) \otimes vh$, where u and vh are 2D unitary arrays and s is a 1D array of a's singular values. When a is higher-dimensional, SVD is applied in stacked mode as explained below.

Parameters: a: (..., M, N) array_like

A real or complex array with a. $ndim \ge 2$.

full_matrices : bool, optional

If True (default), u and vh have the shapes (..., M, M) and (..., N, N), respectively. Otherwise, the shapes are (..., M, K) and (..., K, N), respectively, where $K = \min(M, N)$.

compute_uv: bool, optional

Whether or not to compute u and vh in addition to s. True by default.

Returns:

u: { (..., M, M), (..., M, K) } array

Unitary array(s). The first a. ndim - 2 dimensions have the same size as those of the input a. The size of the last two dimensions depends on the value of $full_matrices$. Only returned when $compute_uv$ is True.

s: (..., K) array

Vector(s) with the singular values, within each vector sorted in descending order. The first a ndim - 2 dimensions have the same size as those of the input a.

奇异值分解与主成分分析

- $X = UDV^T$
- 考虑X的变换Y = XV = UD(维度重组)
- $DC_Y = \frac{1}{N}Y^TY = \frac{1}{N} = \frac{1}{N}D^TU^TUD = \frac{1}{N}D^2$ 是个对角矩阵
- ▶ 各个维度之间不相关
- ▶ 对角元的大小——这一维自身的方差
- ► 按方差大小排列,得到第1,2,...,r个主成分
- ▶ 方差小的几个主成分可以认为是噪声,将其丢弃——降维